

第二章 基础知识

机器学习

本章目录

- 机器学习的基本概念
- 机器学习的分类及概述
- 机器学习的关键思想
- 机器学习与人工智能的关系

机器学习的基本概念

■ 为什么要机器学习？


现实世界的问题都比较复杂，很难通过规则来手工实现。



2	6	8	9	3	4	7	5	6
3	4	7	9	5	5	6	7	2
5	8	7	0	9	4	3	5	4
5	2	3	4	9	5	6	7	8

机器学习 \approx 构建一个映射函数

➤ 语音识别 $\bullet f(\text{语音信号}) = \text{“你好”}$



➤ 图像识别 $\bullet f(\text{猫的图片}) = \text{“猫”}$



➤ 围棋 $\bullet f(\text{棋局}) = \text{“5-5”}$



➤ 对话系统 $\bullet f(\text{“你好”}) = \text{“今天天气真不错”}$

机器学习的基本概念

■ **什么是机器学习：**人工智能的一个分支。主要是设计和分析一些让计算机可以自动“学习”的算法，是一类从数据中自动分析获得规律，并利用规律对未知数据进行预测的算法。机器学习与推断统计学联系尤为密切，也被称为**统计机器学习**。

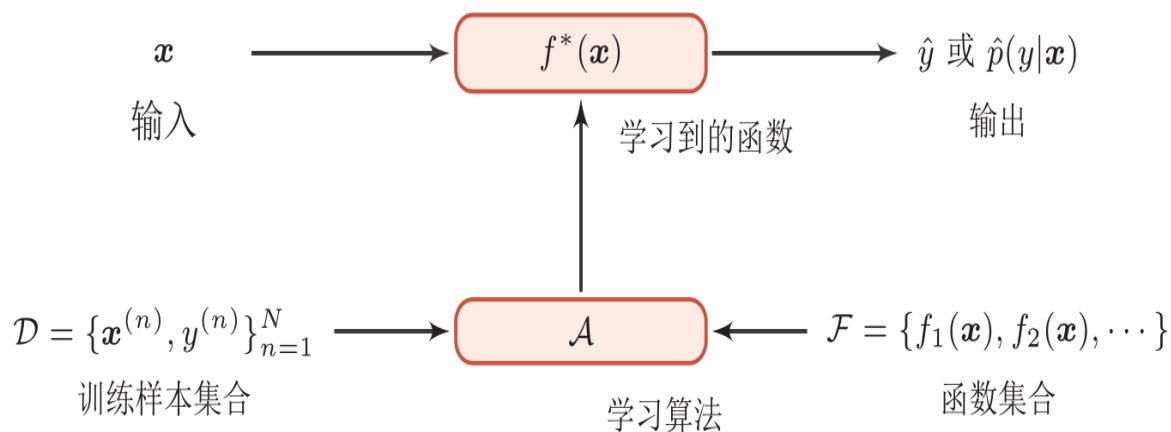
机器学习有下面几种定义：

- 机器学习是一门人工智能的科学，该领域的主要研究对象是人工智能，特别是如何在经验学习中改善具体算法的性能。
- 机器学习是对能通过经验自动改进的计算机算法的研究。
- 机器学习是利用数据或以往的经验，以优化计算机程序的性能。



什么是机器学习？


- 机器学习：通过算法使得机器能从大量数据中学习规律从而对新的样本做决策。
- 规律：决策（预测）函数




挑西瓜
为例

常见的机器学习问题



• 回归



• 分类




• 聚类



• 给西瓜打分



• 看西瓜好坏



• 让相似西瓜抱团儿

机器学习的基本概念

• 名词解释

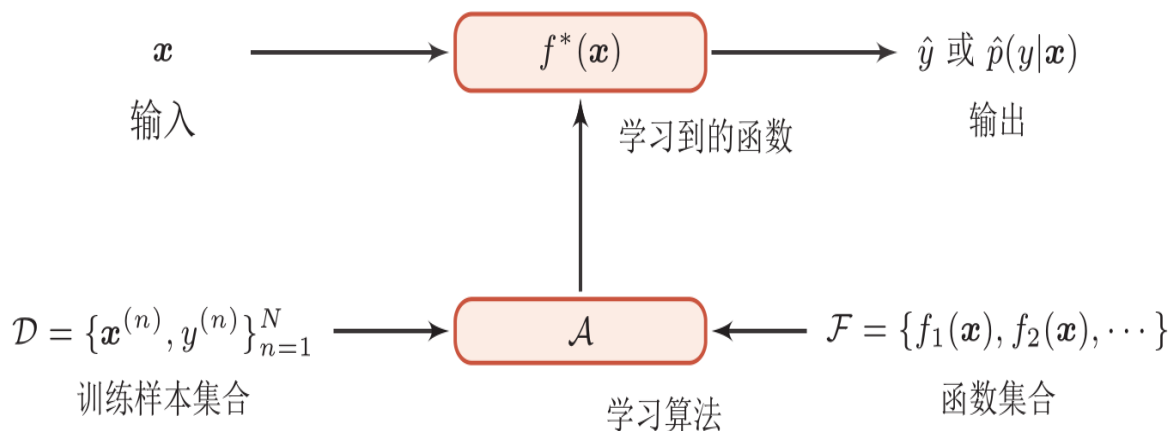


- **特征**(Feature): 西瓜的颜色, 大小, 形状, 产地, 品牌等
- **标签**(Label): 连续值, 西瓜的甜度、水分、成熟度的综合打分; 离散值, 西瓜的“好” “坏” 标签
- 我们通常用一个 D 维向量 $x = [x_1, x_2, \dots, x_D]^T$ 表示一个西瓜的所有特征构成的向量, 称为**特征向量**(Feature Vector), 其中每一维表示一个特征
 - **标签**通常用标量 y 来表示
- 我们可以将一个标记好特征以及标签的西瓜看作一个**样本**(Sample), 也经常称为**示例**(Instance)
- **数据集**(Data Set): 一组样本构成的集合。一般将数据集分为两部分:
- **训练集**(Training Set): 用来训练模型的样本 (训练样本) 的集合
- **测试集**(Test Set): 用来检验模型好坏的样本 (测试样本) 的集合

机器学习的基本概念

• 机器学习的内涵

- 我们希望让计算机从一个函数集合 $F = \{f_1(x), f_2(x), \dots\}$ 中自动寻找一个“最优”的函数 $f^*(x)$ 来近似每个样本的特征向量 x 和标签 y 之间的真实映射关系



- 预测标签的值或者标签的条件概率

- 独立同分布 (IID)
样本独立地从相同的数据分布 $p(x, y)$ 中抽取

- 寻找最优函数 $f^*(x)$ 是机器学习的关键任务
 - 通过学习算法 (Learning Algorithm) \mathcal{A} 来完成
 - 这个寻找过程通常称为学习 (Learning) 或训练 (Training)

机器学习的三要素

• 模型

• 线性方法

$$f(\mathbf{x}, \theta) = \mathbf{w}^T \mathbf{x} + b$$

• 广义线性方法

$$f(\mathbf{x}, \theta) = \mathbf{w}^T \phi(\mathbf{x}) + b$$

• 解决学什么

• 学习准则

• 期望风险


$$\mathcal{R}(f)$$

$$= \mathbb{E}_{(\mathbf{x}, y) \sim p_r(\mathbf{x}, y)} [\mathcal{L}(f(\mathbf{x}), y)]$$

• 解决学成什么样

• 优化算法

• 梯度下降



• 解决怎么学

机器学习的三要素


• 模型

- 输入空间 \mathcal{X} 和输出空间 \mathcal{Y} 构成了一个样本空间
- 样本空间中的样本 $(x, y) \in \mathcal{X} \times \mathcal{Y}$, x 和 y 之间的关系可以描述为:
 - 未知的**真实映射函数** $y = g(x)$, 或
 - **真实条件概率分布** $p_r(y|x)$
- 模型是 $g(x)$ 或 $p_r(y|x)$ 的近似
- 我们不知道 $g(x)$ 或 $p_r(y|x)$ 的具体形式, 因而只能根据经验来假设一个函数集合 \mathcal{F} , 称为**假设空间** (Hypothesis Space)
 - 选择一个理想的**假设** (Hypothesis) $f^* \in \mathcal{F}$

- 假设空间 \mathcal{F} 通常为一个参数化的函数族

$$\mathcal{F} = \{f(x; \theta) | \theta \in \mathbb{R}^D\}$$

其中 $f(x; \theta)$ 是参数为 θ 的函数, 也称为**模型** (Model), D 为参数的数量



- 以**线性回归** (Linear Regression) 为例
模型:

$$f(x, \theta) = w^T x + b$$

机器学习的三要素

• 学习准则

- 训练集 $\mathcal{D} = \{(\mathbf{x}^{(n)}, y^{(n)})\}_{n=1}^N$ 应当由 N 个**独立同分布** (Independent and Identically Distributed, IID)的样本组成
 - 样本分布 $p_r(\mathbf{x}, y)$ 必须固定 (可以未知)
 - 如果 $p_r(\mathbf{x}, y)$ 本身可变, 无法通过这些数据学习

- 一个好的模型 $f(\mathbf{x}, \theta^*)$ 应该在所有 (\mathbf{x}, y) 的可能取值上都与真实映射函数 $y = g(\mathbf{x})$ 一致

$$|f(\mathbf{x}, \theta^*) - y| < \varepsilon$$

或与真实条件概率分布一致

$$|f_y(\mathbf{x}, \theta^*) - p_r(y|\mathbf{x})| < \varepsilon$$

- 模型的好坏通过期望风险来度量

$$R(\theta) = E_{(\mathbf{x}, y) \sim p_r(\mathbf{x}, y)} [L(y, f(\mathbf{x}, \theta))], \quad L(y, f(\mathbf{x}, \theta)) \text{ 为损失函数}$$

机器学习的三要素

- 学习准则

- 损失函数 例:

0-1损失函数
$$\mathcal{L}(y, f(\mathbf{x}; \theta)) = \begin{cases} 0 & \text{if } y = f(\mathbf{x}; \theta) \\ 1 & \text{if } y \neq f(\mathbf{x}; \theta) \end{cases}$$
$$= I(y \neq f(\mathbf{x}; \theta)),$$

平方损失函数
$$\mathcal{L}(y, f(\mathbf{x}; \theta)) = \frac{1}{2} (y - f(\mathbf{x}; \theta))^2.$$

交叉熵损失函数
$$L(y, f(x, \theta)) = - \sum_{c=1}^C y_c \log f_c(x, \theta)$$

三分类问题，一样本的标签向量为 $y=[0,0,1]^T$ ，模型预测的标签分布为 $f(x, \theta)=[0.3,0.3,0.4]^T$ ，
则其交叉熵为： $-(0 \times \log(0.3) + 0 \times \log(0.3) + 1 \times \log(0.4)) = -\log(0.4)$

机器学习的三要素

- 风险最小化准则
 - 期望风险未知，通过经验风险近似

- 给定一个训练集 $\mathcal{D} = \{(\mathbf{x}^{(n)}, y^{(n)})\}_{n=1}^N$ ，我们可以计算的是
经验风险(Empirical Risk)，即在训练集上的平均损失：

$$\mathcal{R}_{\mathcal{D}}^{emp}(\theta) = \frac{1}{N} \sum_{n=1}^N \mathcal{L}(y^{(n)}, f(\mathbf{x}^{(n)}; \theta)).$$

- 实践：寻找一个参数 θ^* ，使得经验风险函数最小化

$$\theta^* = \arg \min_{\theta} \mathcal{R}_{\mathcal{D}}^{emp}(\theta),$$

- 称为**经验风险最小化** (Empirical Risk Minimization, ERM) 准则


- 经验风险最小化原则很容易导致模型在训练集上错误率很低，但是在未知数据上错误率很高
- 所谓的**过拟合** (Overfitting)

机器学习的三要素

• 过拟合与欠拟合

- 和过拟合相反的一个概念是欠拟合(Underfitting)
 - 模型不能很好拟合训练数据, 训练集上错误率高
 - 模型能力不足造成
 - 过拟合和欠拟合示例

定义 2.1-过拟合: 给定一个假设空间 \mathcal{F} , 一个假设 f 属于 \mathcal{F} , 如果存在其他的假设 f' 也属于 \mathcal{F} , 使得在训练集上 f 的损失比 f' 的损失小, 但在整个样本空间上 f' 的损失比 f 的损失小, 那么就说假设 f 过度拟合训练数据 [Mitchell, 1997].






机器学习的三要素

• 优化算法

- 机器学习问题转化成为一个**最优化**问题
 - 寻找参数 θ^* 使经验风险最小化

$$\theta^* = \arg \min_{\theta} \mathcal{R}_D^{emp}(\theta),$$



- 梯度下降法
- 随机梯度下降法

- 机器学习中的优化又可以分为参数优化和超参数优化
 - 参数：模型 $f(x; \theta)$ 中的参数 θ
 - 超参数：用来定义模型结构或优化策略的参数

- 机器学习 \neq 优化！
 - 例：最优化不考虑过拟合问题

本章目录

- 机器学习的基本概念
- 机器学习的分类及概述
- 机器学习的关键思想
- 机器学习与人工智能的关系

机器学习的分类

1. 按标签信息来源分类：

- 监督学习
- 无监督学习
- 强化学习

2. 按学习方法分类（温斯顿，1977）

- 机械式学习、指导式学习、示例学习、类比学习、解释学习等。
- 符号学习、非符号学习（连接学习）

机器学习的分类

3. 按推理方式分类：

- 基于演绎的学习（解释学习）。
- 基于归纳的学习（示例学习、发现学习等）。

4. 按综合属性分类：

- 归纳学习、分析学习、连接学习、遗传式学习等。

机器学习的分类-Wiki


- **监督学习**：从给定的训练数据集中学习出一个模型，当新的数据到来时，可以根据这个模型预测结果。监督学习的训练集要求是包括输入和预期输出，也可以说是特征和标签。训练集中的样本需要标注（有标签）。
- **无监督学习**：训练集没有标签。
- **半监督学习**：介于监督学习与无监督学习之间。
- **强化学习**：机器为了达成目标，随着环境的变动，而逐步调整其行为，并评估每一个行动之后所到的回馈是正向的或负向的。

监督学习


■ 监督学习 (Supervised Learning)

- 已知输入和输出的情况下训练出一个模型，将输入映射到输出
- 通过学习标记的训练样本来构建预测模型，并依此模型推测新的实例
- 输出可以是一个连续的值（称为回归分析），或是预测一个分类标签（称作分类）

Housing price prediction.




Housing price prediction.



无监督学习

■ 无监督学习 (Unsupervised Learning)

- 不给定事先标记过的训练示例，自动对输入的数据进行分析
- 不需要数据标注，对大数据分析很重要，但在实际应用中性能受限
- 包括聚类、降维等



监督/无监督学习

- **Classification problem**

x : watermelons

y : which class belongs to



Good

Bad

Good



Good or Bad ?

- **Regression problem**

x : watermelons

y : real-value response



30

40

35




How much?

- **Clustering problem**

x : watermelons

y : ?



?

?

?



?

监督学习

- 支持向量机
- 决策树
- 朴素贝叶斯
- 逻辑回归
- 卷积神经网络
-

无监督学习

- 聚类：K-均值
- 降维：PCA
- 自编码器
-


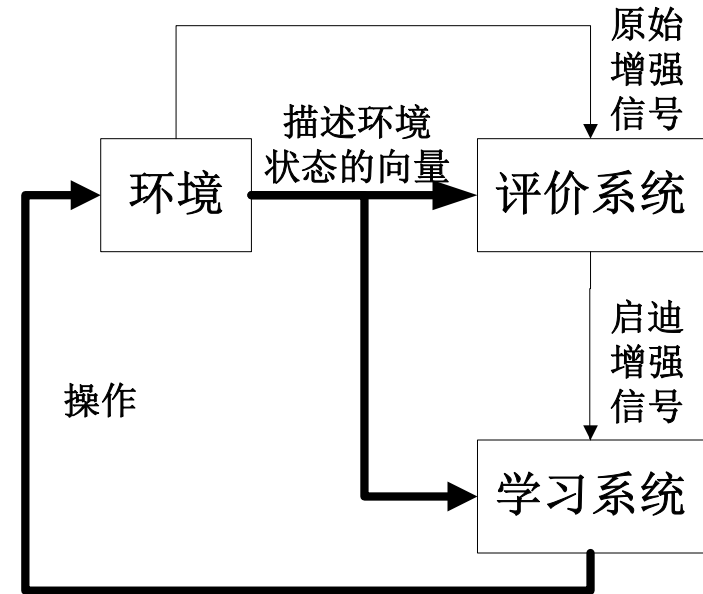
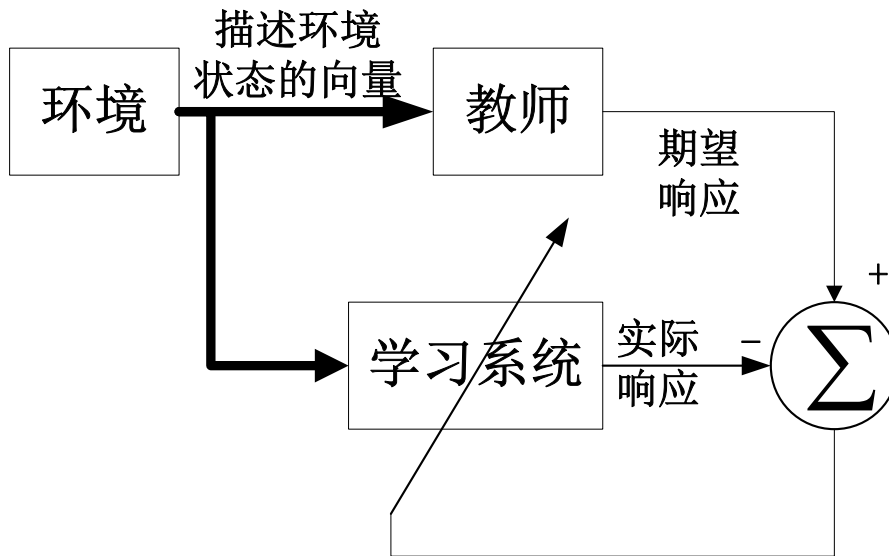
强化学习

- 强化学习（Reinforcement learning）中外部环境对系统输出结果只给出评价信息（奖励或惩罚），而不是正确答案，学习系统通过那些受惩动作改善自身的性能。
- 强化学习理论受到行为主义心理学启发，侧重在线学习并试图在探索-利用（exploration-exploitation）间保持平衡。
- 强化学习通过接收环境对动作的奖励（反馈）获得学习信息并更新模型参数。
- 四个元素：agent，环境状态，行动，奖励

- 强化学习的目标：获得最多的累计奖励
 - Policy based, 关注点是智能体的行为策略
 - Value based, 关注点是衡量回报的多少
 - Model based, 关注点是预测环境如何变化



监督学习vs无监督学习vs强化学习



弱监督学习

■ 弱监督学习 (Weakly Supervised Learning)


监督学习 → 数据标注成本太高；无监督学习 → 学习过程困难、发展缓慢



弱监督学习

数据标签允许是不完全的、不确切、不精确的

- 不完全监督
- 不确切监督
- 不精确监督



弱监督学习

■ 弱监督学习

“weak supervision” is very common

- incomplete



Image classification

It is easy to get a huge number of images from the Internet, but only a small subset of images can be annotated due to the human cost.

- inexact



Important target detection

Usually we only have image-level labels rather than object-level labels.

- inaccurate



Crowdsourcing data analysis

when the image annotator is careless or weary, or some images are difficult to categorize.

弱监督学习普遍存在
也更接近人类的学习方式


弱监督学习

- 为了解决不完全监督，我们可以考虑两种主要技术，主动学习和半监督学习。一种是有人类干预的，一种是没有人类干预的。
- 为了解决不确切监督，我们可以考虑多示例学习。
- 为了解决不精确监督，我们考虑带噪学习。

主动学习

- 在这些未标记数据中，主动学习 (Active learning) 尝试选择最有价值的未标记实例进行查询。最有价值指的是信息性和代表性。主动学习的目标是最小化查询的数量。

Active learning (Incomplete supervision)
With Human Intervention



Active learning assumes that the ground-truth labels of unlabeled data can be queried from an oracle.

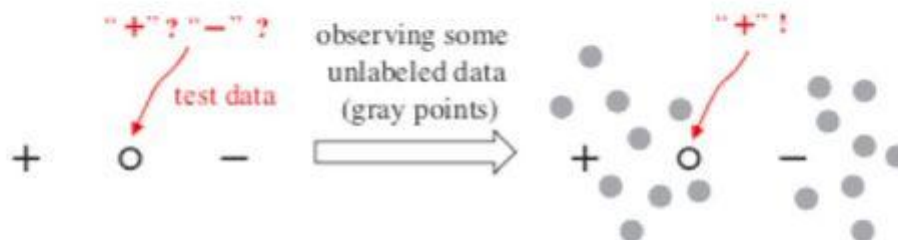
In these unlabeled data, active learning attempts to select the most **valuable** (informativeness and representativeness) unlabeled data to query.

Goal : minimize the number of queries

半监督学习

- 半监督学习 (Semi-supervised learning) 尝试在不查询人类专家的情况下利用未标注的数据

Semi-supervised learning (Incomplete supervision)
Without Human Intervention



Semi-supervised learning attempts to exploit unlabeled data without querying human experts.

Here, although the unlabeled data points do not clearly have label information, they implicitly convey some information about data distribution that can be helpful for predictive modeling.

多示例学习

- 多示例学习 (Multi-instance learning)
- 训练数据集中每一个数据看做一个包(Bag), 每个包由多个示例(Instance)构成, 每个包有一个可见的标签。
- 多示例学习假设每一个正包必须存在至少一个关键示例。
- 多示例学习的过程就是通过模型对包及其包含的多个实例进行分析预测得出包的标签。

Multi-instance learning (Inexact supervision)

Bag :
Tiger (Y)




Image bag generators

Instance1 :



Instance2 :



...

Instance9 :



...

Instance16 :



Actually, almost all supervised learning algorithms have their multi-instance peers.

Goal: predict labels for **unseen bags** by analyzing bags and instances

Multi-instance learning exists widely in the real world, and the potential application prospects are very large.


带噪学习

- 带噪学习 (Learning with label noise) 基本的思想是识别潜在的误分类样本, 然后尝试进行修正。

Learning with label noise (Inaccurate supervision)


In practice, a basic idea is to identify the potentially mislabeled samples, and then try to make some correction.

For example, a data-editing method constructs a relative neighborhood graph



早期机器学习-机械式学习

- 机械式学习 (rote learning) 又称**记忆学习**，或**死记式学习**：通过直接记忆或者存储外部环境所提供的信息达到学习的目的，并在以后通过对知识库的检索得到相应的知识直接用来求解问题。
- 机械式学习实质是**用存储空间来换取处理时间**。



机械学习的学习模型

早期机器学习-机械式学习

• 典型例子： 1959年，塞缪尔(A. L. Samuel)的国际跳棋程序CHECKERS。

- 国际跳棋，国际上最流行的棋类游戏；
- 历史悠久，其历史可以推前到公元前3000年；
- 规则简单；
- 战胜国际跳棋冠军。

A. L. Samuel*

Some Studies in Machine Learning Using the Game of Checkers. II—Recent Progress

Abstract: A new signature table technique is described together with an improved book learning procedure which is thought to be much superior to the linear polynomial method described earlier. Full use is made of the so called “alpha-beta” pruning and several forms of forward pruning to restrict the spread of the move tree and to permit the program to look ahead to a much greater depth than it otherwise could do. While still unable to outplay checker masters, the program’s playing ability has been greatly improved.



布局



兵走法



兵跳吃



兵连跳吃

兵变王



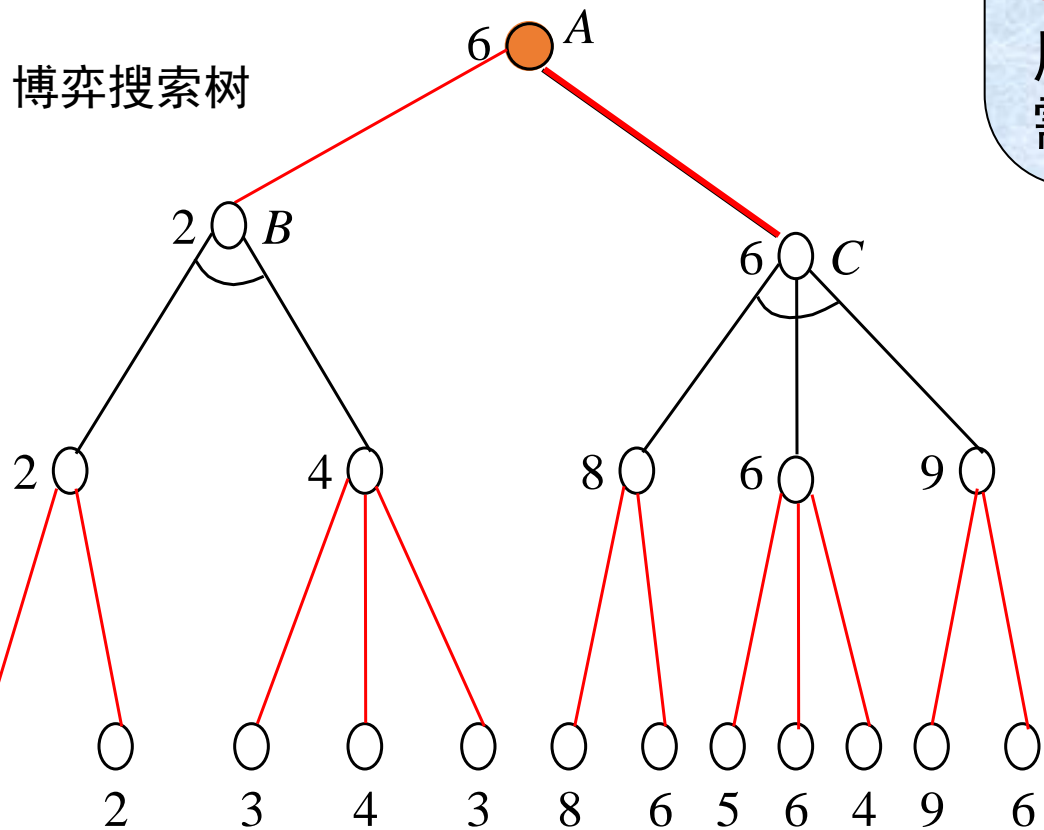
王走法




王跳吃

早期机器学习 -机械式学习

• 塞缪尔的跳棋程序 CHECKERS



- 在给定搜索深度下用估价函数对格局进行评分，通过倒推计算求出上层节点的倒推值，决定当前的最佳走步。
- 下次遇到相同情况，直接利用倒推值决定最佳走步，不需重新计算。




以 A 为结点的博弈树




华中科技大学


HUAZHONG UNIVERSITY OF SCIENCE AND TECHNOLOGY



Red in position 16 can move to 12 (16-12)



Red in position 13 can move to 8 or 9 (13-8 or 13-9)



**** Combination, ● Black to Move (BTM), ● Red To Move (RTM), More Moves, // cutoff, \ A bad move, K (key) Move Create a King. ABCDEH is a winning path, ABCDFH is almost a winning path.

早期机器学习-机械式学习

机械学习的主要问题：

- **存储组织信息**：要采用适当的存储方式，使检索速度尽可能地快。
- **环境的稳定性与存储信息的适用性问题**：机械学习系统必须保证所保存的信息适应于外界环境变化的需要。
- **存储与计算之间的权衡**：对于机械学习来说很重要的一点是它不能降低系统的效率。

早期机器学习-指导式学习

- **指导式学习** (learning by being told) 又称**嘱咐式学习**或**教授式学习**: 由外部环境向系统提供一般性的指示或建议, 系统把它们具体地转化为细节知识并送入知识库中。在学习过程中要反复对形成的知识进行评价, 使其不断完善。可用于专家系统的知识获取。
- **指导式学习的学习步骤**:
 - (1) 征询指导者的指示或建议;
 - (2) 把征询意见转换为可执行的内部形式;
 - (3) 加入知识库;
 - (4) 评价。

早期机器学习-指导式学习

步骤（1）：征询指导者的指示或建议

- 简单征询：指导者给出一般性的意见，系统将其具体化。
- 复杂征询：系统不仅要求指导者给出一般性的建议，而且还要具体地鉴别知识库中可能存在的问题，并给出修改意见。
- 被动征询：系统只是被动地等待指导者提供意见。
- 主动征询：系统不只是被动地接受指示，而且还能主动地提出询问，把指导者的注意力集中在特定的问题上。

早期机器学习-指导式学习

步骤（2）：把征询意见转换为可执行的内部形式

- 学习系统应具有把用约定形式表示的征询意见转化为计算机内部可执行形式的能力，并且能在转化过程中进行语法检查及适当的语义分析。

步骤（3）：加入知识库

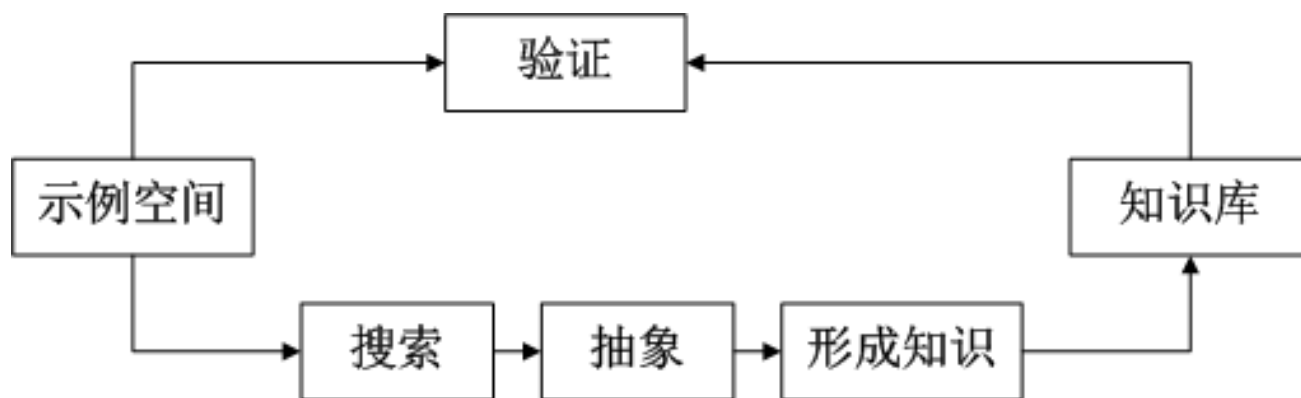
- 在加入过程中要对知识进行一致性检查，以防止出现矛盾、冗余、环路等问题。

步骤（4）：评价

- 评价方法：对新知识进行经验测试，即执行一些标准例子，然后检查执行情况是否与已知情况一致。

早期机器学习-示例学习

- 示例学习（learning from examples，实例学习或从例子中学习）：通过从环境中取得若干与某概念有关的例子，经归纳得出一般性概念的一种学习方法。
- 示例学习中，外部环境（教师）提供一组例子（正例和反例），然后从这些特殊知识中归纳出适用于更大范围的一般性知识，它将覆盖所有的正例并排除所有反例。



示例学习的学习模型

早期机器学习-示例学习



- 示例空间

编号	色泽	根蒂	敲声	好瓜
1	青绿	卷缩	浊响	是
2	乌黑	卷缩	浊响	是
3	青绿	硬挺	清脆	否
4	乌黑	稍卷	沉闷	否

- 目标：好瓜的概念？

- 假设：好瓜 = (色泽=?) \wedge (根蒂=?) \wedge (敲声=?)

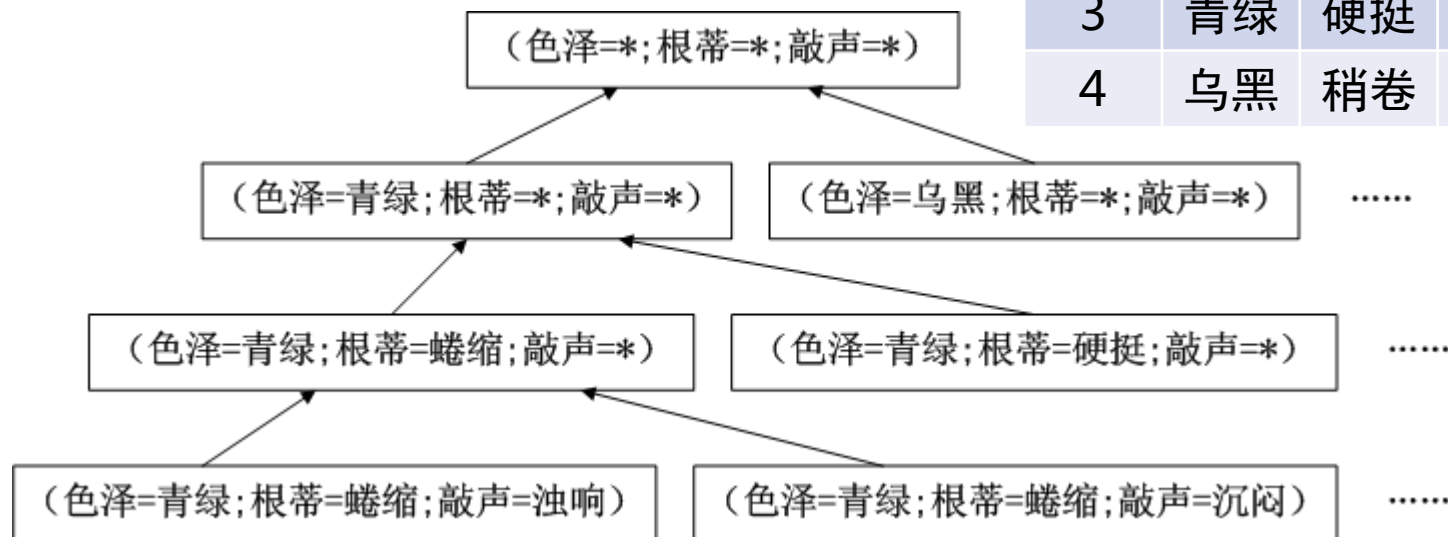


华中科技大学

HUAZHONG UNIVERSITY OF SCIENCE AND TECHNOLOGY


早期机器学习-示例学习

- 假设空间



编号	色泽	根蒂	敲声	好瓜
1	青绿	蜷缩	浊响	是
2	乌黑	蜷缩	浊响	是
3	青绿	硬挺	清脆	否
4	乌黑	稍卷	沉闷	否

- 版本空间



华中科技大学


HUAZHONG UNIVERSITY OF SCIENCE AND TECHNOLOGY

现代机器学习-深度学习

- 把原始数据通过一些简单但非线性的模型转变为更高层次、更加抽象的表达
- 可以学习非常复杂的函数
- 实质是通过构建具有很多隐层的模型和海量的训练数据来学习更有用的特征、提升分类或预测的准确性

现代机器学习-迁移学习

- 迁移学习（Transfer learning）：将已经学习过的知识迁移应用到新的问题中
- 在数据独立同分布不成立的条件下



现代机器学习-迁移学习

- 研究可以用哪些知识在不同的领域或者任务中进行迁移学习，即不同领域之间有哪些**共有知识**可以迁移。
- 研究在找到了迁移对象之后，针对具体问题所采用**哪种迁移学习的特定算法**，即如何设计出合适的算法来提取和迁移共有知识。
- 研究**什么情况下适合迁移**，迁移技巧是否适合具体应用，其中涉及到负迁移的问题。

◇ 迁移学习的关键点

- 用什么迁移(What to transfer)
- 如何进行迁移(How to transfer)
- 何时适合迁移(When to transfer)

桥梁是什么？

基于实例的迁移

基于特征的迁移

基于共享参数的迁移

假设领域间具有公共知识结构

现代机器学习-迁移学习

- 样本迁移

- 从源领域中挑选出，对目标领域的训练有用的实例

- 特征迁移

- 找出源领域与目标领域之间共同的特征表示，然后利用这些特征进行知识迁移

- 模型迁移

- 找到源数据和目标数据的空间模型之间的共同参数或者先验分布，从而可以通过进一步处理，达到知识迁移的目的

更多.....

- Representation Learning 表示学习
- Self-supervised Learning 自监督学习
- Metric Learning 度量学习
- Contrastive Learning 对比学习
- Adversarial Learning 对抗学习
- Meta Learning 元学习
-

本章目录

- 机器学习的基本概念
- 机器学习的分类及概述
- 机器学习的关键思想
- 机器学习与人工智能的关系

归纳偏置

(Inductive Bias)

- 很多学习算法经常会对学习的问题做一些假设，这些假设就称为**归纳偏置**
 - 在最近邻分类器中，我们会假设在特征空间中，一个小的局部区域中的大部分样本都同属一类。
 - 在朴素贝叶斯分类器中，我们会假设每个特征的条件概率是互相独立的。
 - 归纳偏置在贝叶斯学习中也经常称为**先验** (Prior)。

常用的定理

- 奥卡姆剃刀原理(Occam's Razor)
 - 如无必要，勿增实体



常用的定理

- 没有免费午餐定理(No Free Lunch Theorem, NFL)
 - 对于基于迭代的最优化算法，不存在某种算法对所有问题（有限的搜索空间内）都有效。如果一个算法对某些问题有效，那么它一定在另外一些问题上比纯随机搜索算法更差



常用的定理

- 丑小鸭定理(Ugly Duckling Theorem)
 - 丑小鸭与白天鹅之间的区别和两只白天鹅之间的区别一样大



本章目录

- 机器学习的基本概念
- 机器学习的分类及概述
- 机器学习的关键思想
- 机器学习与人工智能的关系

机器学习与人工智能的关系

- 机器学习是人工智能的基础



机器学习与人工智能的关系

- 基于机器学习的人工智能的优势和局限性

优势	局限性
借助数据和工具，轻松训练新的解决方案	有炒作之嫌，研究者和从业者需要设定合理预期
有大量不同算法来解决许多类型的问题	需要大量干净的、可能有标签的数据
解决所有 AI 领域的问题，经常接近或超过人类的能力水平	数据存在的问题（如过时、不完整或恶意注入不良数据）可能会使结果产生偏差
无需人类专业知识或复杂的知识工程，解决方案来自于实例	有些算法，特别是基于统计的机器学习算法，依赖于手动特征工程

机器学习与人工智能的关系

• 基于机器学习的人工智能的优势和局限性

优势	局限性
深度学习可自动提取特征，形成具有复杂感知和理解能力的解决方案	系统逻辑未经编程，必须进行学习。这可能会导致较为主观的结果，例如相互竞争的激活级别，而这需要精确的答案（例如，合规性或验证问题的特定正确或错误答案）。
经过训练的机器学习模型可以在其他解决方案的组合物或组件中进行复制和重用	尽管现在有超参数优化工具，选择最好的算法、网络架构和超参数仍然需要专业知识，并且需要迭代。
作出预测或产生结果通常比传统的推断或算法快	训练包含大型数据集的复杂问题需要大量的时间和计算资源
训练机器学习模型的算法可设计为分布式和一次通过式方法，从而提高可伸缩性并缩短训练时间	通常很难通过观察模型结构和训练结果来解释模型是如何得出结果的。
可以在可扩展的高性能基础设施上进行训练和部署	尽管输出可以反映数值“置信度”，但是大多数算法是一步解决问题，因此没有推理链或部分结果可用。
使用常见机制（如微服务/API）部署，以便于与其他系统集成	